

İÇİNDEKİLER

TEŞEKKÜR	i
TABLolar LİSTESİ	ii
ŞEKİLLER LİSTESİ	iii

TEŞEKKÜR 4

TABLolar LİSTESİ 5

ŞEKİLLER LİSTESİ 6

ÖZET 7

ABSTRACT 8

BÖLÜM 1. GİRİŞ 9

1.1.	ZAMAN SERİSİ	10
1.1.1.	Otoregresif Bütünleşik Hareketli Ortalama Modeli(ARIMA).....	17
1.2.	MAKİNE ÖĞRENMESİ	19
1.2.1.	DERİN ÖĞRENME	20
1.2.1.1.	Yapay Sinir Ağları	21
1.2.1.2.	Tekrarlamalı Sinir Ağı (RNN)	24
1.2.1.3.	LSTM.....	25
1.2.1.4.	GRU	26
1.3.	Hata Metrikleri	28
1.3.1.	Ortalama Mutlak Hata (MAE - Mean Absolute Error).....	28
1.3.2.	Kök Ortalama Kare Hata (RMSE - Root Mean Square Error)	28
1.3.3.	R-kare (R^2 - Coefficient of Determination)	28
1.3.4.	Ortalama Mutlak Yüzde Hata (MAPE - Mean Absolute Percentage Error)	
	29	
1.4.	Literatür Taraması	30

BÖLÜM 2. PROBLEMİN TANIMI 31

BÖLÜM 3. PROBLEMİN ÇÖZÜMÜ İÇİN TAKİP EDİLECEK AŞAMALAR 32

3.1.	ARIMA	32
3.2.	LSTM-GRU-SimpleRNN.....	33

BÖLÜM 4. UYGULAMA34

4.1.	ARIMA modeli uygulaması	34
------	-------------------------------	----

4.1.1.	Verilerin Elde Edilmesi.....	34
4.1.2.	Zaman serisi oluřturma	34
4.1.3.	Durađanlık kontrolü.....	34
4.1.4.	Mevsimsellik kontrolü.....	35
4.1.5.	Model oluřturma.....	35
4.1.6.	Tahmin yapma	37
4.1.7.	Eđitim ve test verilerinin hazırlanması	37
4.1.8.	Hata Metriklerinin Oluřturulması	37
4.2.	LSTM-GRU-SimpleRNN Modellerinin Uygulanması	38
4.2.1.	Verilerin Elde Edilmesi.....	38
4.2.2.	Veri Ön İřleme	38
4.2.3.	Özellik Seçimi	38
4.2.4.	Verilerin yeniden řekillendirilmesi	39
4.2.5.	Eđitim ve test setlerinin hazırlanması.....	39
4.2.6.	LSTM, GRU, Simple RNN Modellerinin oluřturulması ve eđitilmesi	40
4.2.7.	Tahminlerin yapılması ve deđerlendirilmesi	40
4.2.8.	Hata Metriklerinin Hesaplanması	43
BÖLÜM 5.	ANALİZ	44
BÖLÜM 6.	GERÇEKÇİ KISITLAR VE KOřULLAR ALTINDA DEđerLENDİRME	46
BÖLÜM 7.	SONUÇ	47
KAYNAKLAR		49

TABLÖLAR LİSTESİ

Tablo 1.ARIMA hata skorları..... 38

Tablo 2.LSTM-GRU-SimpleRNN hata skorları..... 43

Tablo 3. Tüm modellerin hata skorları	44
--	----

ŞEKİLLER LİSTESİ

Şekil 1. Durağan zaman serisi	13
Şekil 2. Durağan olmayan zaman serisi	13

Şekil 3.Otokorelasyon grafikleri	16
Şekil 4.ReLu fonksiyonu.....	21
Şekil 5.Tanh fonksiyonu	22
Şekil 6.Sigmoid fonksiyonu	22
Şekil 7.LSTM hücresi	25
Şekil 8.GRU hücresi.....	26
Şekil 9.APPLE hisse senedi	35
Şekil 10.Durağanlık grafiği	36
Şekil 11.Otokorelasyon grafiği	36
Şekil 12.Kısmi otokorelasyon grafiği	37
Şekil 13.Korelasyon matrisi	39
Şekil 14.Model mimarisi	40
Şekil 15.Model parametreleri.....	40
Şekil 16. GRU tahmin değerlerinin dağılımları	41
Şekil 17.GRU kayıp fonksiyonu	41
Şekil 18.GRU gerçekleşen ve tahmin kapanış değerleri	41
Şekil 19.LSTM kayıp fonksiyonu	41
Şekil 20.LSTM tahmin değerleri.....	41
Şekil 21.LSTM gerçekleşen ve tahmin kapanış değerleri.....	42
Şekil 22.SimpleRNN kayıp fonksiyonu	42
Şekil 23.LSTM tahmin değerleri.....	42
Şekil 24.SimpleRNN gerçekleşen ve tahmin kapanış değerleri.....	43
Şekil 25.Hata skorlarına göre modeller grafiği	44
Şekil 26.Korelasyon değerlerine göre modeller	45
Şekil 27.Model karşılaştırması grafiği	47

ÖZET

Bu çalışma, makine öğrenmesi ve derin öğrenme algoritmalarını kullanarak Apple hisse senedi fiyatlarının tahmin edilmesini amaçlamaktadır. Çalışmada, Otoregresif Bütünleşik

Hareketli Ortalama (ARIMA), Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU) ve Simple Recurrent Neural Network (SimpleRNN) modelleri kullanılmıştır. Veriler, Yahoo Finance üzerinden 12.06.2000 - 10.06.2024 tarihleri arasındaki Apple hisse senedi fiyatlarıdır.

Modellerin performansı, Ortalama Mutlak Hata (MAE), Kök Ortalama Kare Hata (RMSE), Ortalama Mutlak Yüzde Hata (MAPE) ve Korelasyon Katsayısı (r) gibi hata metrikleri ile değerlendirilmiştir. Sonuçlar, GRU modelinin düşük MAE ve MAPE değerleri ile en iyi performansı sergilediğini, LSTM modelinin ise düşük RMSE değeri ile büyük hataları minimize etmede başarılı olduğunu göstermiştir. SimpleRNN modeli yüksek korelasyon katsayısına sahip olmasına rağmen diğer hata metriklerinde düşük performans sergilemiştir. ARIMA modeli ise diğer modellere kıyasla en düşük performansı göstermiştir. Bu çalışma, makine öğrenmesi ve derin öğrenme algoritmalarının finansal zaman serilerinde güçlü araçlar olduğunu ve Apple hisse senedi tahmininde etkili sonuçlar verdiğini ortaya koymaktadır. Ancak, hisse senedi piyasalarının doğası gereği yüksek volatilité ve öngörülemezlik, tahminlerin doğruluğunu sınırlayan önemli faktörlerdir. Bu nedenle, hisse senedi tahmin modellerinin geliştirilmesi ve iyileştirilmesi için sürekli olarak yeni yöntemler ve daha kapsamlı veri setleri üzerinde çalışılması gerekmektedir.

Anahtar kelimeler: Hisse senedi tahmini, makine öğrenmesi, Apple, LSTM, GRU.

ABSTRACT

This study aims to predict Apple stock prices using machine learning and deep learning algorithms. In the study, Autoregressive Integrated Moving Average (ARIMA), Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU), and Simple Recurrent Neural Network (SimpleRNN) models were used. The data consists of Apple stock prices between 12.06.2000 and 10.06.2024, obtained from Yahoo Finance. The performance of the models was evaluated using error metrics such as Mean Absolute Error (MAE), Root Mean Square Error (RMSE), Mean Absolute Percentage Error (MAPE), and Correlation Coefficient (r). The results showed that the GRU model performed the best with low MAE and MAPE values, while the LSTM model was successful in minimizing large errors with its low RMSE value. Although the SimpleRNN model had a high correlation coefficient, it showed lower performance in other error metrics. The ARIMA model demonstrated the lowest performance compared to the other models. This study reveals that machine learning and deep learning algorithms are powerful tools in financial time series and provide effective results in predicting Apple stock prices. However, the high volatility and unpredictability inherent in stock markets are significant factors that limit the accuracy of predictions. Therefore, continuous efforts to develop and improve stock price prediction models using new methods and more comprehensive datasets are necessary.

Keywords: Stock prediction, machine learning, Apple, LSTM, GRU.

BÖLÜM 1. GİRİŞ

Finansal piyasalar, ekonomik dinamiklerin ve çeşitli dışsal faktörlerin etkisi altında karmaşık ve öngörülemez yapılarıyla tanınır. Küresel ekonomik koşullar, siyasi olaylar, doğal afetler, teknolojik yenilikler ve şirket içi gelişmeler gibi birçok faktör, finansal piyasalardaki dalgalanmaları etkiler. Bu dinamik yapı, piyasa katılımcıları için hem fırsatlar hem de riskler yaratır. Özellikle hisse senedi piyasaları, yatırımcılar için büyük bir cazibe merkezi olmuştur. Yüksek getiri potansiyeli sunması, birçok yatırımcıyı hisse senetlerine yönlendirmektedir. Ancak, bu yüksek getiri potansiyeli, beraberinde büyük riskleri de getirir. Hisse senedi fiyatları, anlık olarak büyük dalgalanmalar gösterebilir ve bu dalgalanmalar, yatırımcıların sermayelerini kaybetme riskini de artırır. Bu nedenle, hisse senedi fiyatlarını doğru tahmin edebilmek, yatırımcılar ve finansal analistler için kritik bir öneme sahiptir. Doğru tahminler, yatırımcıların daha bilinçli kararlar almasını sağlar ve böylece riskleri minimize ederken getirileri maksimize etme olasılığını artırır. Yatırımcılar, gelecekteki fiyat hareketlerini öngörebilmek için çeşitli analiz yöntemleri kullanır. Geleneksel olarak, temel analiz ve teknik analiz, hisse senedi fiyat tahminlerinde yaygın olarak kullanılan yöntemlerdir. Temel analiz, şirketin mali durumunu, ekonomik göstergeleri ve sektör trendlerini inceleyerek hisse senedinin gerçek değerini belirlemeye çalışırken, teknik analiz, geçmiş fiyat hareketlerine ve işlem hacmine dayanarak gelecekteki fiyat hareketlerini tahmin etmeye çalışır. Temel analiz, özellikle uzun vadeli yatırımlar için önemlidir. Şirketin gelir tablosu, bilanço, nakit akışı gibi mali tablolarının yanı sıra, sektördeki rekabet durumu, ekonomik koşullar ve gelecekteki büyüme potansiyeli gibi faktörleri dikkate alır. Bu analiz türü, hisse senedinin gerçek değerini belirlemeye çalışır ve piyasadaki fiyat dalgalanmalarının ötesine geçerek, şirketin gerçek performansına odaklanır. Temel analizin en büyük avantajı, yatırımcılara derinlemesine ve kapsamlı bir değerlendirme sunmasıdır. Ancak, piyasanın anlık ve kısa vadeli dalgalanmalarını öngörmede yetersiz kalabilir. Teknik analiz ise, tamamen fiyat hareketleri ve işlem hacmi gibi tarihsel verilere dayanır. Bu analiz türü, piyasanın geçmiş performansını inceleyerek, gelecekteki fiyat hareketlerini öngörmeye çalışır. Teknik analiz, kısa vadeli yatırımlar için oldukça kullanışlıdır ve yatırımcıların alım-satım kararlarını hızlı bir şekilde verebilmelerine olanak tanır. Grafikler, göstergeler ve trend analizleri gibi araçlar kullanılarak, hisse senedinin gelecekteki hareketleri tahmin edilmeye çalışılır. Zaman serisi analizi de finansal tahminlemede kullanılabilecek geçmiş verilere dayanarak gelecekteki olayları tahmin etmek için kullanılan bir yöntemdir. Zaman serisi analizine dayanan tahmin modelleri,

finansal veri analizinde sıklıkla kullanılmaktadır. ARIMA (Autoregressive Integrated Moving Average) modeli, bu amaçla kullanılan en yaygın ve etkili yöntemlerden biridir. ARIMA modeli, zaman serisi verilerini geçmiş gözlemlerine dayalı olarak modelleyerek gelecekteki değerleri tahmin etmeye çalışır. Model, üç temel bileşenden oluşur: otoregresif (AR), entegre (I), ve hareketli ortalama (MA). Bu bileşenler, zaman serisinin trend ve mevsimsellik gibi özelliklerini dikkate alarak, gelecekteki veri noktalarını öngörmeye yardımcı olur. ARIMA modelinin hisse senedi tahmininde kullanılması, yatırımcılara ve portföy yöneticilerine, piyasa dalgalanmalarını ve potansiyel yatırım fırsatlarını daha iyi anlama imkanı sunar. Modelin, geçmiş fiyat verilerini analiz ederek gelecekteki fiyat hareketlerini tahmin etme yeteneği, yatırım kararlarının daha bilinçli ve veri odaklı olmasını sağlar.

1.1. ZAMAN SERİSİ

Zaman serisi, belirli zaman dilimlerinde kaydedilen gözlemler kümesidir. Genellikle iki ana kategoriye ayrılır: ayrık zaman serileri ve sürekli zaman serileri. Ayrık zaman serileri, gözlemlerin belirli ve sabit aralıklarda (saatlik, günlük, aylık, yıllık vb.) yapıldığı serilerdir. Örneğin, her gün kaydedilen sıcaklık değerleri bir ayrık zaman serisidir. Sürekli zaman serileri ise gözlemlerin sürekli bir zaman aralığında kaydedildiği serilerdir. Bu, her an kaydedilebilen verileri içerir.

Matematiksel olarak, bir zaman serisi ardışık zamanlarda ölçülen veri noktalarının bir dizisi olarak tanımlanabilir: $\{Y_t\}; t = 0, 1, 2, \dots$. Burada t , zamanı temsil ederken, y_t ise o zaman diliminde gözlemlenen değeri, yani rastgele değişkeni ifade eder. Bir zaman serisinde yer alan veriler, olayların meydana geldiği kronolojik sıraya göre düzenlenmiştir. (Cochrane, 1997).

Zaman Serisinin Bileşenleri

Zaman serilerinin bileşenleri, çeşitli değişim türlerini içerir.

Mevsimsel değişim (Seasonal variation): Yılın belirli zamanlarında tekrarlanan desenlerdir. Örneğin, yaz aylarında artan dondurma satışları mevsimsel bir değişimdir. Bu bileşen, veriler yalnızca yıllık olarak kaydedilirse tespit edilemez.

Eğilim (Trend): Veri setinde uzun vadede gözlenen sabit bir yukarı veya aşağı yönlü hareketlerdir. Bu, ortalama düzeydeki uzun vadeli değişim olarak tanımlanabilir.

Çevrimsel değişim (Cyclic variation): Bir yıldan uzun süren döngüsel değişimlerdir. Örneğin, beş yıllık iş çevrimleri veya biyolojik ritimler.

Düzensiz dalgalanmalar (Irregular fluctuations): Eğilim, mevsimsellik ve çevrimsel etkiler çıkarıldıktan sonra geriye kalan, rastgele ve tahmin edilemez değişimlerdir. Zaman serilerinde

genellikle toplamsal (additive) ve çarpımsal (multiplicative) olmak üzere iki farklı model kullanılır. Bu modeller, zaman serisinin dört bileşeni olan gözlem (y_t), eğilim (T_t), mevsimsel değişim (S_t), döngüsel değişim (C_t) ve düzensiz varyasyon (I_t) bileşenlerini içerir.

Toplamsal Model: $Y_t = T_t + S_t + C_t + I_t$


Çarpımsal Model: $Y_t = T_t \times S_t \times C_t \times I_t$

Çarpımsal model, bileşenlerin birbirinden bağımsız olmadığını ve birbirlerini etkileyebileceğini varsayar. Toplamsal modelde ise, bileşenlerin birbirinden bağımsız olabileceği kabul edilir.

Durağan Zaman Serisi, Durağan (sabit) zaman serisi, zaman içinde istatistiksel özellikleri değişmeyen bir seridir. Bir zaman serisinin durağan olması, serinin ortalaması ve varyansının zamanla değişmemesi anlamına gelir. Yani, serinin özellikleri zaman kaymasından etkilenmez. Matematiksel olarak, bir zaman serisi, gözlemlerinin ortak olasılık dağılımı zaman içinde değişmezse durağan olarak kabul edilir. Örneğin, $y_t, y_{t+1}, \dots, y_{t+n}$ gözlemlerinin ortak olasılık dağılımı, $y_{t+k}, y_{t+k+1}, \dots, y_{t+k+n}$ gözlemlerinin ortak olasılık dağılımı ile aynıysa, seri durağandır. Bu, özellikle $n=0$ olduğunda, yani y_t değişkeninin tüm zaman periyotları için aynı olasılık dağılımına sahip olması durumunda geçerlidir. Bu durumda, dağılım $f(y)$ olarak ifade edilebilir. Durağan zaman serisi analizinde, serinin ortalama, varyans ve otokorelasyon gibi istatistiksel özellikleri zamanla sabit kalır. Bu özellik, modelleme ve tahmin süreçlerinde önemli avantajlar sağlar, çünkü durağan seriler daha kolay analiz edilir ve tahmin modelleri daha güvenilir sonuçlar verir.


Aşağıdaki grafikte, durağan ve durağan olmayan zaman serilerine örnekler verilmiştir.

Durağan Zaman Serisi



Şekil 1.Durağan zaman serisi

Durağan Olmayan Zaman Serisi



Şekil 2.Durağan olmayan zaman serisi

Durağanlık, bir zaman serisinin istatistiksel olarak dengede olması anlamına gelir. Bu, zaman serisinin belirli özelliklerinin zamanla değişmediğini gösterir. Durağan bir zaman serisi, sabit bir ortalama ve sabit bir varyansa sahiptir.

Matematiksel olarak, durağanlık şu şekilde tanımlanabilir:

Sabit Ortalama (Constant Mean): $\mu_y = E(y) = \int_{-\infty}^{\infty} y f(y) dy$

Sabit Varyans (Constant Variance): $\sigma_y^2 = V(y) = \int_{-\infty}^{\infty} (y - \mu_y)^2 f(y) dy$

Bu ifadeler, bir zaman serisinin ortalamasının ve varyansının zaman boyunca sabit olduğunu gösterir. Durağan zaman serileri, istatistiksel analiz ve modelleme süreçlerinde daha güvenilir ve tutarlı sonuçlar sağlar.

Otokovaryans, Otokorelasyon ve Kısmi Otokorelasyon Fonksiyonları

Durağan bir zaman serisinde, gözlemler arasındaki ilişkiler zamanın herhangi bir noktasında değişmez. Bu tür serilerde, belirli bir zaman periyodunda kaydedilen bir gözlem ile belirli bir gecikme sonrası kaydedilen diğer gözlem arasındaki ilişki, serinin doğası hakkında önemli bilgiler sağlar. Bu ilişkiler otokovaryans, otokorelasyon ve kısmi otokorelasyon fonksiyonları ile ölçülür.

Otokovaryans (Autocovariance)

Otokovaryans, bir zaman serisinin belirli bir gecikme süresi ile ayrılmış iki gözlem arasındaki kovaryanstır. Matematiksel olarak k gecikmesindeki otokovaryans şu şekilde tanımlanır:

$$\gamma_k = Cov(Y_t, Y_{t+k}) = E[(Y_t - \mu)(Y_{t+k} - \mu)]$$

Burada:

Y_t ve Y_{t+k} serinin t ve $t + k$ zamanındaki değerleridir.

μ ise serinin ortalamasıdır.

E değeri beklenen değeri (ortalama) ifade eder.

Otokovaryans fonksiyonu, farklı gecikme değerleri ($k = 0, 1, 2, \dots$) için otokovaryans değerlerinin bir kümesini ifade eder.

Otokorelasyon (Autocorrelation) Otokorelasyon, belirli bir gecikme süresindeki iki gözlem arasındaki ilişkinin normalleştirilmiş ölçüsüdür. k gecikmesindeki otokorelasyon katsayısı şu şekilde tanımlanır:

$$\rho_k = \frac{Y_k}{Y_0}$$

Burada:

- Y_k mesindeki otokovaryanstır.
- Y_0 serinin sıfır gecikmedeki kovaryansıdır ve serinin varyansına eşittir.

Kısmi Otokorelasyon (Partial Autocorrelation)

Kısmi otokorelasyon, belirli bir gecikmedeki iki gözlem arasındaki doğrudan ilişkiyi, aradaki diğer gözlemlerin etkisini ortadan kaldırarak ölçer. k dereceden kısmi otokorelasyon şu şekilde hesaplanır:

$$\eta_{kk} = \text{Corr}(Y_t - \Gamma(Y_t | Y_{t+1}, \dots, Y_{t+k-1}), Y_{t+k} - \Gamma(Y_{t+k} | Y_{t+1}, \dots, Y_{t+k-1}))$$

Burada:

- $\Gamma(W | Z), Z$ üzerine W 'nin en iyi doğrusal projeksiyonunu, yani ortalama karesel hatayı en aza indiren ifadeyi temsil eder.
- $\text{Corr}(A, B)$ A ve B arasındaki korelasyonu ifade eder.

Kısmi otokorelasyon fonksiyonu (PACF), farklı gecikme değerlerinde hesaplanan kısmi otokorelasyon katsayılarının bir grafiğidir. Bu fonksiyon, zaman serisinin yapısını ve modellemeye yönelik önemli bilgileri ortaya çıkarır.

Beyaz Gürültü

Otokorelasyon göstermeyen zaman serilerine beyaz gürültü (white noise) serisi denir. Beyaz gürültü serileri, her bir otokorelasyon katsayısının sıfıra yakın olmasını bekler. Ancak, bazı rastgele varyasyonlar nedeniyle otokorelasyon katsayıları tam olarak sıfır olmayabilir. Beyaz gürültü serisi için, otokorelasyon fonksiyonundaki değerlerin %95'inin $\pm 2/\sqrt{T}$ aralığında olması beklenir. Burada, T zaman serisinin uzunluğunu temsil eder.


Eğer otokorelasyon fonksiyonundaki değerlerden biri veya birkaçı bu sınırların dışındaysa veya değerlerin %5'inden fazlası bu sınırların dışına çıkıyorsa, bu serinin beyaz gürültü olmadığını gösterir. Bu durumda, seride otokorelasyon olduğu ve beyaz gürültü serisi olarak kabul edilemeyeceği anlaşılır.

Fark Alma İşlemi

Matematiksel olarak, birinci dereceden fark alma işlemi şu şekilde tanımlanır: $Y'_t = Y_t - Y_{t-1}$. Burada, Y_t zaman serisinin t zamanındaki değeri Y_{t-1} ise bir önceki zaman dilimindeki değeridir. Bu işlem, serinin trendini ve mevsimsel bileşenlerini azaltarak veriyi durağan hale getirmeye çalışır.

Otokorelasyon fonksiyon grafiği (ACF), verilerin durağan olup olmadığını belirlemek için kullanışlıdır. Durağan bir zaman serisi için otokorelasyon fonksiyonu, hızlı bir şekilde sıfıra düşer. Buna karşılık, durağan olmayan bir zaman serisinin otokorelasyon fonksiyonu, yavaşça azalır. Bu davranışlar, verilerin zaman çizelgesine bakmanın yanı sıra, otokorelasyon fonksiyonu grafiği ile de gözlemlenebilir.

Şekil 2.4'te, Google hisselerinin 200 günlük fiyatlarından oluşan zaman serisinin otokorelasyon fonksiyonu grafiği ve fark alınmış otokorelasyon fonksiyonu grafiği gösterilmiştir. İlk grafikte, serinin durağan olup olmadığını belirlemek için otokorelasyon fonksiyonunun yavaş mı hızlı mı azaldığına dikkat edilir. İkinci grafikte, fark alma işlemi sonrasında otokorelasyon fonksiyonunun hızlı bir şekilde sıfıra düşmesi beklenir, bu da serinin durağan hale geldiğini gösterir.



Şekil 3. Otokorelasyon grafikleri

Zaman Serisinin İstatistiksel Tahminleme Modelleri

Zaman serisi verileri farklı biçimlerde modellenebilir ve çeşitli istatistiksel süreçlerle temsil edilebilir. Literatürde yaygın olarak kullanılan iki temel doğrusal zaman serisi modeli Otoregresif (Autoregressive - AR) ve Hareketli Ortalama (Moving Average - MA) modelleridir. Bu modelleri birleştiren Otoregresif Hareketli Ortalama (Autoregressive Moving Average - ARMA) ve Otoregresif Bütünleşik Hareketli Ortalama (Autoregressive Integrated Moving Average - ARIMA) modelleri de yaygın olarak kullanılır. ARIMA modelleri, ünlü Box-Jenkins yöntemine dayanır.

Otoregresif Modeli

p dereceli otoregresif model (AR(p)), bir zaman serisinin önceki p gözlemiyle kendini açıklamasıdır. Matematiksel olarak şu şekilde ifade edilir:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \omega_t$$

Burada:

- $\phi_1, \phi_2, \dots, \phi_p$ modelin otoregresif katsayılarıdır.
- ω_t , ortalaması sıfır ve varyansı σ^2 , beyaz gürültü serisidir.

Hareketli Ortalama Modeli

q dereceli hareketli ortalama model (MA(q)), bir zaman serisinin önceki q hata terimiyle kendini açıklamasıdır. Matematiksel olarak şu şekilde ifade edilir:

$$Y_t = \omega_t + \theta_1 \omega_{t-1} + \theta_2 \omega_{t-2} + \dots + \theta_q \omega_{t-q}$$

Burada:

- $\theta_1, \theta_2, \dots, \theta_q$ modelin hareketli ortalama katsayılarıdır.

ω_t , ortalaması sıfır ve varyansı σ^2 olan beyaz gürültü serisidir

Otoregresif Hareketli Ortalama Modeli

Otoregresif Hareketli Ortalama Modeli (ARMA(p,q)), otoregresif ve hareketli ortalama modellerinin bir kombinasyonudur. Matematiksel olarak şu şekilde ifade edilir:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \omega_t + \theta_1 \omega_{t-1} + \theta_2 \omega_{t-2} + \dots + \theta_q \omega_{t-q}$$

1.1.1. Otoregresif Bütünleşik Hareketli Ortalama Modeli (ARIMA)

ARMA modelleri yalnızca durağan zaman serileri için uygundur. Ancak, birçok sosyo-ekonomik ve finansal zaman serisi durağan değildir. Bu nedenle, ARIMA modeli, durağan olmayan zaman serilerini modellemek için geliştirilmiştir. ARIMA modeli, fark alma yöntemi ile seriyi durağan hale getirir ve ARMA modelini uygular.

ARIMA(p,d,q) modeli, p dereceli otoregresif, d dereceli fark alma ve q dereceli hareketli ortalama bileşenlerinden oluşur. Matematiksel olarak şu şekilde ifade edilir:

$$\phi_p(B)(1-B)^d Y_t = \theta_q(B) \omega_t$$

Burada:

- p , modelin otoregresif derecesini ifade eder.
- d , fark alma derecesini belirtir (genellikle $d = 1$ yeterlidir).
- q , hareketli ortalama derecesini gösterir.
- B , geri kaydırma operatörüdür.

Bu model, trend ve mevsimsel bileşenlerin etkisini ortadan kaldırarak seriyi daha iyi analiz etmeye olanak tanır.

Birim Kök Testleri

Birim kök testleri, zaman serilerinin durağan olup olmadığını belirlemek için kullanılan istatistiksel hipotez testleridir. Durağan olmayan zaman serileri, tahmin modellerinde sorun yaratabileceğinden, bu testler serilerin fark alınması gerekip gerekmediğini objektif olarak belirlemede kullanılır.

Kwiatkowski-Phillips-Schmidt-Shin

(KPSS)

Testi

KPSS testi, zaman serilerinin durağan olup olmadığını belirlemek için kullanılan popüler birim kök testlerinden biridir. KPSS testinin önemli bir özelliği, hipotezlerin diğer birim kök

testlerine göre tersine çevrilmiş olmasıdır. Bu testteki boş hipotez, zaman serisinin durağan olduğunu varsayar. p-Değeri 0.05'in altında ise, boş hipotezin reddedilmesine neden olur. Bu durumda, zaman serisinin durağan olmadığı ve fark almanın gerekli olduğu anlamına gelir.

Finansal piyasalardaki belirsizlik ve karmaşıklık, geleneksel analiz yöntemlerinin yeterliliklerini sorgulamaktadır. Finansal piyasalarda, yatırımcıların karşılaştığı belirsizliklerin ve öngörülemez değişimlerin artması, yeni ve daha gelişmiş tahmin yöntemlerine duyulan ihtiyacı artırmaktadır. Bu bağlamda, son yıllarda makine öğrenmesi ve yapay zeka gibi ileri teknolojiler, hisse senedi tahminlerinde yeni bir yaklaşım sunmuştur. Makine öğrenmesi, büyük veri setleri üzerinde çalışarak karmaşık desenleri ve ilişkileri tespit etme yeteneği sayesinde, hisse senedi fiyat tahminlerinde önemli bir araç haline gelmiştir. Bu teknolojiler, geleneksel yöntemlerin ötesine geçerek, daha hassas ve öngörülebilir tahminler sunma potansiyeline sahiptir.

Makine öğrenmesi yöntemleri, geçmiş verilerdeki desenleri tanıma ve bu desenleri gelecekteki olayları tahmin etmede kullanma yeteneği ile öne çıkar. Bu yöntemler, özellikle büyük ve çeşitli veri setlerinin analiz edilmesinde etkili olur. Finansal piyasalar gibi sürekli değişen ve geniş veri setlerinin bulunduğu alanlarda, makine öğrenmesi tekniklerinin uygulanabilirliği ve etkinliği daha belirgin hale gelmektedir. Bu nedenle, hisse senedi fiyatlarının doğru ve etkin bir şekilde tahmin edilebilmesi, sadece yatırımcılar için değil, aynı zamanda piyasaların genel sağlığı ve istikrarı için de büyük bir önem taşımaktadır. İleriye dönük olarak, makine öğrenmesi yöntemlerinin bu alandaki katkılarını ve potansiyelini araştırmak, finansal analiz ve yatırım stratejilerinin geliştirilmesinde yeni fırsatlar sunabilir.

Makine öğrenmesi tekniklerinin finansal piyasalarda uygulanması, yatırım stratejilerinin ve portföy yönetiminin yeniden şekillendirilmesine olanak tanır. Örneğin, gözetimli öğrenme yöntemleri, hisse senedi fiyatlarının gelecekteki değerlerini tahmin etmek için geniş veri setleri üzerinde eğitilebilir. Bu yöntemler, geçmiş fiyat verileri, işlem hacmi, ekonomik göstergeler ve şirket performans verileri gibi çeşitli veri kaynaklarını kullanarak gelecekteki fiyat hareketlerini tahmin edebilir. Ayrıca, gözetimsiz öğrenme yöntemleri, hisse senedi piyasalarında gizli desenleri ve ilişkileri keşfetmek için kullanılabilir. Bu, yatırımcıların piyasa trendlerini daha iyi anlamalarına ve yatırım stratejilerini buna göre uyarlamalarına yardımcı olabilir. Derin öğrenme ve sinir ağları gibi daha ileri makine öğrenmesi teknikleri de hisse senedi tahminlerinde önemli bir rol oynayabilir. Bu teknikler, çok katmanlı yapıları sayesinde karmaşık ve neredeyse keşfedilemeyen desenleri tanıyabilir. Özellikle derin öğrenme yöntemleri, büyük veri setleri üzerinde etkili bir şekilde çalışabilir ve bu veri

setlerindeki en ince ayrıntıları bile yakalayabilir. Bu da, hisse senedi fiyat tahminlerinin daha hassas ve güvenilir olmasını sağlar.

Makine öğrenmesi yöntemlerinin kullanımı, yatırımcılara ve finansal analistlere çeşitli avantajlar sunar. Öncelikle, bu yöntemler büyük veri setlerini işleyebilme ve bu verilerden anlamlı bilgiler çıkarabilme yeteneğine sahiptir. Bu sayede, piyasaların dinamiklerini ve gelecekteki hareketlerini daha iyi anlama fırsatı sunar. Ayrıca, makine öğrenmesi algoritmaları, sürekli olarak yeni verilerle güncellenebilir ve böylece tahminlerin doğruluğu zamanla artırılabilir. Bu, yatırımcıların ve analistlerin karar verme süreçlerinde daha esnek ve uyumlu olmalarını sağlar. Makine öğrenmesi aynı zamanda, finansal piyasalardaki anormallikleri ve fırsatları tespit etmede de etkili olabilir. Anomali tespiti ve zaman serisi analizleri gibi teknikler, piyasada beklenmeyen değişiklikleri ve fırsatları hızlı bir şekilde belirleyebilir. Bu da, yatırımcıların bu fırsatları değerlendirmelerine ve piyasa risklerini daha iyi yönetmelerine yardımcı olabilir.

Hisse senedi fiyat tahmininde makine öğrenmesi yöntemlerinin kullanılması, finansal piyasalarda yeni bir dönemin başlangıcını işaret etmektedir. Geleneksel analiz yöntemlerinin sınırlamalarını aşan bu teknolojiler, yatırımcılara ve finansal analistlere daha doğru ve öngörülebilir tahminler sunarak, riskleri minimize etme ve getirileri maksimize etme fırsatı sağlar. Bu tez çalışmasında, makine öğrenmesi yöntemlerinin hisse senedi fiyat tahminlerindeki etkinliğini ve uygulanabilirliğini inceleyerek, finansal piyasalarda daha bilinçli ve veri odaklı kararlar alınmasına katkıda bulunmayı hedefliyoruz. Ayrıca, makine öğrenmesi tekniklerinin finansal analiz ve yatırım stratejileri üzerindeki etkilerini ve potansiyelini keşfetmeyi amaçlıyoruz. Bu çalışma, yatırımcılara ve analistlere, finansal piyasaların karmaşıklığını daha iyi anlama ve bu karmaşıklık içinde daha bilinçli kararlar alma fırsatı sunacaktır.

1.2. MAKİNE ÖĞRENMESİ

Makine öğrenmesi, bilgisayarların veriden öğrenme ve bu öğrendiklerini kullanarak belirli görevleri otomatik olarak yerine getirme yeteneği kazanmasını sağlayan bir yapay zeka (AI) alt dalıdır. Makine öğrenmesi, programlama olmadan öğrenme ve performansını iyileştirme yeteneğine dayanır. Bu süreçte, bilgisayarlar veri setlerinden desenler ve ilişkiler çıkararak bu bilgileri gelecekteki veri analizlerinde kullanır.

Gözetimli Öğrenme (Supervised Learning): Eğitim verisi, giriş ve çıkış etiketleri ile birlikte sunulur. Model, bu etiketli verilerden öğrenir ve yeni, etiketsiz veriler üzerinde tahminler

yapar. Örnek Algoritmalar: Lineer regresyon, lojistik regresyon, karar ağaçları, destek vektör makineleri (SVM).

Gözetimsiz Öğrenme (Unsupervised Learning): Eğitim verisi yalnızca giriş verilerini içerir, çıkış etiketleri yoktur. Model, verilerdeki desenleri ve yapıları keşfetmeye çalışır. Örnek Algoritmalar: Kümeleme (k-means, hiyerarşik kümeleme), boyut indirgeme (PCA, t-SNE).

Yarı Gözetimli Öğrenme (Semi-supervised Learning): Hem etiketli hem de etiketsiz verilerin bir kombinasyonunu kullanır. Genellikle, etiketli verilerin az olduğu ve etiketsiz verilerin bol olduğu durumlarda kullanılır.

Pekiştirmeli Öğrenme (Reinforcement Learning): Dinamik bir ortamda etkileşim yoluyla optimal davranışları öğrenmeyi amaçlayan bir makine öğrenmesi metodolojisidir. Bu öğrenme yöntemi, belirli bir hedefe ulaşmak için alınan aksiyonların ödülleri veya cezaları yoluyla değerlendirildiği bir süreçtir. Pekiştirmeli öğrenme, sıralı karar verme problemlerinde etkin bir şekilde kullanılır ve özellikle oyunlar, robotik ve otonom sistemler gibi alanlarda yaygın olarak uygulanır. Örnek Algoritmalar: Q-learning, derin pekiştirmeli öğrenme (deep reinforcement learning).

1.2.1. DERİN ÖĞRENME

Derin öğrenme, makine öğrenmesinin bir alt dalıdır ve özellikle yapay sinir ağları kullanılarak çok katmanlı yapılar aracılığıyla büyük miktarda veriden anlamlı bilgileri otomatik olarak çıkarma ve karmaşık desenleri öğrenme yeteneğine sahiptir. Bu teknoloji, görüntü işleme, doğal dil işleme, ses tanıma ve otonom sistemler gibi çeşitli alanlarda büyük başarılar elde etmiştir. Derin öğrenme modelleri, giriş, gizli ve çıkış katmanlarından oluşan yapay sinir ağları üzerine kuruludur ve eğitim sürecinde verilerden öğrenerek ağırlıkları optimize eder. Örnek olarak, özellikle görüntü işleme ve sınıflandırmada kullanılan Convolutional Neural Networks (CNN) (Evrimli Sinir Ağları), zaman serisi verileri ve dil işleme için uygun olan Recurrent Neural Networks (RNN) (Tekrarlayan Sinir Ağları), uzun vadeli bağımlılıkları öğrenmede etkili olan Long Short-Term Memory (LSTM) (Uzun Kısa Süreli Bellek), veriyi düşük boyutlu bir temsile sıkıştırmak ve yeniden oluşturmak için kullanılan Autoencoders (Otoenkodlayıcılar) ve yeni veri örnekleri üretmek için iki ağın rekabet ettiği Generative Adversarial Networks (GAN) (Üretici Çekişmeli Ağlar) gibi modeller bulunmaktadır.

1.2.1.1. Yapay Sinir Ağları


Yapay sinir ağları, insan beyninin işleyişini model olarak oluşturulmuş karmaşık ağ yapılarıdır. Bu modeller, çok sayıda işlem birimi olan nöronlardan oluşur. Her nöron, bir veya daha fazla bağımsız değişkenden gelen bilgiyi alır, işler ve sonuçları çıktı nöronlarına aktarır. Sinir ağları, katmanlar arası bağlantı ağırlıkları ve bias değerleri üzerinden eğitilir ve bu süreçte genellikle geri yayılım algoritması kullanılır. Aktivasyon fonksiyonu, nöronların çıktılarını sınırlamak veya dönüştürmek için kullanılır. Yapay sinir ağları, özellikle büyük ve karmaşık veri setlerinde, doğrusal olmayan ilişkileri ve etkileşimleri modellemek için uygundur

Aktivasyon Fonksiyonları


Yapay Sinir Ağlarında (YSA) kullanılan aktivasyon fonksiyonları, nöronların çıkışlarını belirlemek için kritik bir rol oynar. En yaygın kullanılan aktivasyon fonksiyonlarından üçü ReLU, Tanh ve Sigmoid'dir.

ReLU (Rectified Linear Unit) fonksiyonu, giriş değerleri pozitif olduğunda giriş değerini döndürür, negatif olduğunda ise sıfır döndürür. Matematiksel olarak, $f(x) = \max(0, x)$ formülü ile tanımlanır. ReLU, basitliği ve hesaplama verimliliği ile öne çıkar ve genellikle gizli katmanlarda kullanılır.


Tanh (Hyperbolic Tangent) fonksiyonu, giriş değerlerini -1 ile 1 arasında sıkıştırır. Bu fonksiyon, $f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ formülü ile ifade edilir. Tanh fonksiyonu, hem negatif hem de pozitif değerler alabilmesi nedeniyle genellikle gizli katmanlarda tercih edilir. Sigmoid fonksiyonu ise giriş değerlerini 0 ile 1 arasında sıkıştırır ve özellikle ikili sınıflandırma problemlerinde kullanılır. Bu fonksiyon, $f(x) = \frac{1}{1 + e^{-x}}$ formülü ile tanımlanır. Sigmoid, olasılık hesaplamaları için uygun bir aktivasyon fonksiyonudur ve çıkış katmanlarında sıkça kullanılır. Bu üç aktivasyon fonksiyonu, yapay sinir ağlarının farklı katmanlarında ve uygulamalarında yaygın olarak kullanılır. Her biri belirli senaryolar için avantajlıdır ve doğru problem için doğru aktivasyon fonksiyonunu seçmek, model performansını önemli ölçüde etkileyebilir.



Şekil 4.ReLu fonksiyonu



Şekil 5.Tanh fonksiyonu



Şekil 6.Sigmoid fonksiyonu

Çok Katmanlı Yapay Sinir Ağı

Çok katmanlı yapay sinir ağı (MLP - Multi Layer Perceptron), gizli katmanlar içeren ve çıkış değerinin yeniden giriş olarak işleme alındığı ağlardan oluşur. Öğrenmeyi iyileştirmek için iki tür işlem vardır:

İleri Doğru İşlem (Feed-Forward): Bir önceki katmanda elde edilen çıktı, yeni ağırlıklarla bir sonraki katmana aktarılır ve tüm ağ boyunca işlemler yeniden yapılır.

Geriye Yayımlı İşlem (Backpropagation): Hesaplanan çıktı değeri ($\hat{y}$) ile gerçek çıktı değeri (y) karşılaştırılır. Aradaki fark bir hata fonksiyonu ile değerlendirilir ve bu hata minimize edilmeye çalışılır. Genellikle, en küçük ortalama kareler (LMS) için eğim iniş yöntemi (gradient descent - GD) kullanılır. Başlangıçta ağırlıklar rastgele seçilir ve öğrenme oranı (η) kullanılarak hata azaltılır. Bu yöntemle, ağırlık değerleri tekrar hesaplanarak ağda yeniden kullanılır ve hata azaltılarak öğrenme iyileştirilir.

$$J(\omega) = \frac{1}{2}(y - \hat{y})^2$$

$$\Delta\omega = -\eta \frac{\partial J}{\partial \omega}$$

1.2.1.2. Tekrarlamalı Sinir Ağı (RNN)

Geleneksel sinir ağları, tüm giriş ve çıkışları bağımsız varsayar, ancak bu her zaman uygun değildir. Tekrarlamalı Sinir Ağı (Recurrent Neural Networks - RNN), birbirine bağımlı giriş verilerini dizi halinde kullanarak çalışır. Örneğin, bir cümledeki bir kelimeyi tahmin etmek için önceki kelimelerin bilgisine ihtiyaç vardır. Bu ağlar, bir diziyi giriş verisi olarak alır ve çıktıları önceki hesaplamalara bağlı olarak tekrarlayarak çalışır. RNN'ler, sinir ağı boyunca bilgiyi tutan bir hafıza gibi işlev görür, ancak pratikte çok fazla adımda hafıza özelliğini kaybedebilir (Haykin, 1999; Hu ve Balasubramaniam, 2008).

RNN'de:

x_t : t anındaki giriş

s_t : t anındaki saklı durum (hafıza). Aşağıdaki gibi hesaplanır:

$$s_t = f(Ux_t + Ws_{t-1})$$

Burada f , tanh veya ReLU gibi doğrusal olmayan bir fonksiyondur.

o_t : t anındaki çıktı. Aşağıdaki gibi hesaplanır :

$$o_t = softmax(Vs_t)$$

RNN, sts_tst ile önceki adımlardaki bilgiyi tutar ve oto_tot ile tüm bilgiyi kullanarak çıktıyı oluşturur. RNN'ler, diğer sinir ağlarından farklı olarak tüm adımlarda aynı parametreleri (U, V, W) kullanır:

U: gizli katman ağırlıkları

V: çıktı katman ağırlıkları

W: gizli durum geçiş ağırlıkları

Bu özellikleri sayesinde, girdiler bir dizi halinde kullanıldığında her adım birlikte çalışır ve öğrenme için gerekli parametre sayısı azalır.

1.2.1.3. LSTM


Long Short-Term Memory (LSTM), Tekrarlamalı Sinir Ağlarının (RNN) bir türüdür ve özellikle uzun süreli bağımlılıkların bulunduğu veri dizilerini modellemek için tasarlanmıştır. LSTM'ler, zaman serileri, metin verisi veya ses verisi gibi dizisel verilerde yaygın olarak kullanılır. RNN'lerin zaman içindeki bağımlılıkları öğrenme kapasitesi sınırlıdır, çünkü uzun dizilerde geçmiş bilgileri hatırlamada zorlanırlar. LSTM'ler ise bu sorunu çözmek için geliştirilmiştir.

LSTM Yapısı: LSTM, iç yapısında üç adet kapıya (gate) sahiptir: unutma kapısı (forget gate), giriş kapısı (input gate) ve çıkış kapısı (output gate). Bu kapılar, hücre durumunu ve gizli durumu kontrol ederek uzun süreli bağımlılıkları öğrenmeyi ve hatırlamayı mümkün kılar.

Unutma Kapısı (Forget Gate): Hücre durumunda hangi bilgilerin tutulacağını veya unutulacağını belirler. Bu kapı, önceki hücre durumu ve mevcut girişten gelen bilgileri kullanarak bir karar verir.

Giriş Kapısı (Input Gate): Yeni gelen bilginin hücre durumuna ne kadarının ekleneceğini belirler. Mevcut giriş ve önceki gizli durum kullanılarak karar verilir.

Çıkış Kapısı (Output Gate): Hücre durumundan hangi bilgilerin çıkışa gönderileceğini belirler. Bu kapı, hücre durumu ve mevcut girişten gelen bilgileri kullanarak bir çıktı üretir.



Şekil 7.LSTM hücresi

Bir LSTM hücresinin yapısı şu şekildedir:

Unutma Kapısı (Forget Gate):

$$f_t = \sigma(W_f \times [h_{t-1}, x_t] + b_f)$$

Bu kapı, önceki hücre durumunun hangi kısmının unutulacağını belirler.

Giriş Kapısı (Input Gate):

$$i_t = \sigma(W_i \times [h_{t-1}, x_t] + b_i)$$

Bu kapı, yeni hücre durumuna eklenecek bilginin miktarını belirler.

Güncellenmiş Hücre Durumu (Cell State):

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{c}_t$$

Yeni hücre durumu, unutma kapısının çıktısı ve giriş kapısının güncellediği bilgi ile belirlenir.

Çıkış Kapısı (Output Gate):

$$o_t = \sigma(W_o \times [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \times \tanh(C_t)$$


Çıkış kapısı, hücre durumundan gönderilecek bilgiyi belirler.

LSTM'ler, uzun süreli bağımlılıkları öğrenme yeteneği nedeniyle birçok uygulamada başarılı sonuçlar elde eder. Bu özellikleri ile dil modelleme, makine çevirisi, konuşma tanıma, zaman serisi tahmini gibi birçok alanda yaygın olarak kullanılır.

1.2.1.4. GRU

GRU (Gated Recurrent Unit), tekrarlayan sinir ağlarının (RNN) bir çeşididir ve zaman serisi verileri gibi dizisel verilerle çalışmak için kullanılır. GRU, RNN'lerin uzun dönem bağımlılık problemlerini çözmek için geliştirilmiştir ve LSTM (Long Short-Term Memory) hücrelerine benzer şekilde çalışır, ancak daha basit bir yapıya sahiptir.

GRU Hücresinin Temel Bileşenleri



Şekil 8.GRU hücresi

Güncelleme Kapısı (Update Gate):

Önceki gizli durumun ne kadarının yeni gizli duruma aktarılacağını belirler.

$$z_t = \sigma(W_z \times x_t + U_z \times h_{t-1})$$

Resetleme Kapısı (Reset Gate):

Önceki gizli durumun ne kadarının unutulacağını kontrol eder.

$$r_t = \sigma(W_r \times x_t + U_r \times h_{t-1})$$

Aday Gizli Durum (Candidate Hidden State):

Resetleme kapısının sonucuna göre geçici yeni gizli durum hesaplanır.

$$\tilde{h}_t = \tanh(W \times x_t + r_t * U \times h_{t-1})$$

Yeni Gizli Durum (New Hidden State):

Güncelleme kapısı ve aday gizli durumun birleşimiyle oluşturulan nihai gizli durumdur.

$$h_t = z_t \times h_{t-1} + (1 - z_t) \times \tilde{h}_t$$

GRU, LSTM'ye göre daha az kapıya sahiptir ve daha basit bir yapısı vardır. GRU, daha az hesaplama gerektirir ve genellikle daha hızlıdır. Belirli uygulamalarda GRU ve LSTM benzer performans gösterebilir, ancak veri setine ve probleme bağlı olarak biri diğerine göre daha iyi olabilir.

1.3. Hata Metrikleri

Hata metrikleri, tahmin modellerinin performansını değerlendirmek için kullanılan ölçütlerdir. Bu metrikler, modelin yaptığı tahminler ile gerçek değerler arasındaki farkları belirleyerek modelin doğruluğunu ve güvenilirliğini analiz etmeye yardımcı olur. Aşağıda, en yaygın kullanılan hata metrikleri ve bunların açıklamaları yer almaktadır.

1.3.1. Ortalama Mutlak Hata (MAE - Mean Absolute Error)

MAE, tahmin edilen değerler ile gerçek değerler arasındaki farkların mutlak değerlerinin ortalamasıdır. Bu metrik, modelin tahmin hatalarının genel büyüklüğünü ölçer.

$$MAE = \frac{1}{n} \sum_{i=1}^N |y_i - \hat{y}_i|$$

y_i : gerçek değerler

$\hat{y}_i$: tahmin edilen değerler

n : örnek sayısı

1.3.2. Kök Ortalama Kare Hata (RMSE - Root Mean Square Error)

RMSE, tahmin edilen değerler ile gerçek değerler arasındaki farkların karelerinin ortalamasının kareköküdür. Bu metrik, hataların büyüklüğünü ölçer ve büyük hatalara daha fazla ağırlık verir.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

y_i : gerçek değerler

$\hat{y}_i$: tahmin edilen değerler

n : örnek sayısı

1.3.3. R-kare (R^2 - Coefficient of Determination)

R^2 , bağımsız değişkenlerin bağımlı değişkenin varyansını ne kadar açıkladığını ölçen bir istatistiktir. 1'e yakın değerler, modelin verileri iyi bir şekilde açıkladığını gösterirken, düşük değerler modelin verileri yeterince açıklamadığını gösterir.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

y_i : gerçek değerler

$\hat{y}_i$: tahmin edilen değerler

$\bar{y}$: gerçek değerlerin ortalaması

n : örnek sayısı

1.3.4.Ortalama Mutlak Yüzde Hata (MAPE - Mean Absolute Percentage Error)

MAPE, tahmin edilen değerler ile gerçek değerler arasındaki farkların mutlak değerlerinin gerçek değerlere oranının ortalamasıdır. Bu metrik, hataların yüzde cinsinden büyüklüğünü ölçer ve verilerin birimleriyle uyumlu değildir.

$$MAPE = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|}$$

Burada:

y_i : gerçek değerler

$\hat{y}_i$: tahmin edilen değerler

n : örnek sayısı

Belirsizlik, olayların gerçekleşme olasılığının bilinmediği durumu ifade eder. Tahmin sürecinde, gelecekteki olayların sonuçlarını ve bu sonuçlara etki edebilecek tüm değişkenleri ve varsayımları tam olarak bilmek mümkün olmadığından, bu durum belirsizlik olarak adlandırılır. Belirsizlik, tahminlerin yapılmasını zorlaştıran ve gelecekteki olayların kesin sonuçlarını öngörmeyi engelleyen bir faktördür (Runde 1998). Olayın sonuçlarıyla ilgili bilgi eksiklerinin bulunduğu ve sonuçların belirli bir liste içinde bulunmadığı durumlarda belirsizlik ön plandadır (Lavoie 1994).

Hisse Senedi Tahmininde Belirsizlik Kavramı, hisse senedi tahmininde belirsizlik piyasaların doğasında var olan ve tahminlerin doğruluğunu etkileyen faktörleri ifade eder. Bu belirsizlikler piyasa volatilitesi, makroekonomik faktörler, şirket performansı ve haberleri, yatırımcı davranışları, jeopolitik olaylar ve model belirsizliklerinden kaynaklanır. Piyasa volatilitesi ani haberler ve olaylar nedeniyle fiyatlarda dalgalanmalara yol açar. Makroekonomik faktörler (faiz oranları, enflasyon) karmaşık ve öngörülemezdir. Şirketlerin

mali durumu ve beklenmeyen haberler fiyatları etkileyebilir. Yatırımcı psikolojisi ve irrasyonel tepkiler dalgalanmalara neden olur. Jeopolitik olaylar (savaşlar, ticaret anlaşmazlıkları) belirsizlik yaratır. Model belirsizlikleri ise veri kalitesi ve model seçiminden kaynaklanır. Belirsizlikleri azaltmak için veri çeşitlendirmesi, gelişmiş modeller, risk yönetimi stratejileri ve gerçek zamanlı veri kullanımı gibi yöntemler uygulanabilir. Bu sayede daha güvenilir ve sağlam tahminler yapılabilir.

1.4. Literatür Taraması

Derin öğrenme yöntemleri ile borsada fiyat tahmini çalışmasında BLSTM-LSTM-GRU modelleri kullanılarak IBM hisse senedi tahmini yapılmıştır. BLSTM modeli ile %63,54 lük bir yöneysel doğruluk değerine ulaşılmıştır. (Şişmanoğlu ve Arkadaşları, 2020) Makine öğrenmesi modelleri ile Petkim (Petrokimya Holding A.Ş) 'nin hisse senedi fiyatının tahminin yapıldığı çalışmada LSTM+Evrişimli Sinir Ağı, RFR(Rassal Orman Regresyonu) modelleri kullanılmış ve hata metriklerine göre kıyaslanmıştır. (Toprak, 2023)

Borsa gelecek değer tahmin çalışmasında New York Borsasında (NYSE) bünyesinde yer alan ETF'lerin yapay sinir ağları ve Bayes Karar Modeli ile tahmin çalışması incelenmiştir. (Bahadır, 2008)

BİST 100 endeksidenki 42 şirketin hisse senedi açılış ve kapanış fiyatlarının tahminin gerçekleştirildiği çalışmada MLP(Çok katmanlı Algılayıcılar), SVM ve LTSM modelleri kullanılmış ve hata metrikleri ile karşılaştırılmıştır. Çalışmada MLP ve LTSM modelleri SVM modeline göre daha tutarlı sonuç vermiştir. (Demirel ve arkadaşları, 2021) Destek Vektör Makineleri ile Hisse Senedi Fiyat Tahmini" başlıklı çalışma, SVM'nin hisse senedi fiyatlarını tahmin etmedeki etkinliğini araştırmıştır. Çalışma, SVM'nin yüksek doğruluk oranlarına sahip olduğunu ve özellikle kısa vadeli tahminlerde başarılı olduğunu göstermektedir. (Kılıç, 2018)

Karar Ağaçları ve Rastgele Ormanlar ile Hisse Senedi Fiyat Tahmini başlıklı çalışma, karar ağaçları ve rastgele orman algoritmalarının hisse senedi fiyat tahminindeki performansını incelemiştir. Çalışma, bu algoritmaların karmaşık veri setlerinde bile yüksek doğruluk sağladığını göstermektedir. (Kaya 2021)

LSTM ile Hisse Senedi Fiyat Tahmini başlıklı çalışma, uzun kısa süreli bellek (LSTM) ağlarının hisse senedi fiyat tahmininde nasıl kullanılabileceğini incelemiştir. Çalışmada, LSTM'nin uzun vadeli bağımlılıkları ve karmaşık desenleri öğrenme yeteneği sayesinde hisse senedi fiyat tahmininde üstün performans gösterdiği bulunmuştur. (Demirci&Eren, 2019)

BÖLÜM 2. PROBLEMİN TANIMI

Günümüz finansal piyasaları, karmaşık dinamikler ve yüksek volatilité nedeniyle hisse senedi fiyatlarının tahmin edilmesini zorlaştırmaktadır. Geleneksel tahmin yöntemleri, bu karmaşıklık ve belirsizlik karşısında genellikle yetersiz kalmaktadır. Makine öğrenmesi teknikleri, büyük veri setlerinden karmaşık desenleri tanımlama ve gelecekteki fiyat hareketlerini daha doğru tahmin etme potansiyeline sahiptir. Ancak, bu tekniklerin etkinliđi ve güvenilirliđi tam olarak anlaşılmamıştır. Çalışmada kullanılacak modeller ile makine öğrenmesi yöntemlerinin güvenilirliđin araştırılmasına ihtiyaç bulunmaktadır.

BÖLÜM 3. PROBLEMİN ÇÖZÜMÜ İÇİN TAKİP EDİLECEK AŞAMALAR

3.1. ARIMA

Çözüm Aşamaları	Yapılan İş	Çözüm Aracı, Yöntem, Teknik, Program vs.
1. Verilerin Elde Edilmesi	Hisse senedi verilerinin toplanması	R Studio, Readr, Yahoo Finance
2. Zaman serisi oluşturma	Zaman serisi verisi oluşturma	R Studio, Tseries
3. Durağanlık Kontrolü	Verinin durağanlık kontrolünün KPSS Testi ile sağlanması	R Studio, Tseries
4. Mevsimsellik Kontrolü	Mevsimsellik kontrolünün sağlanması	R Studio, Tseries
5. Model oluşturma	ARIMA modelinin oluşturulması	R Studio, Tseries
6. Tahmin yapma	Eğitilen model ile hisse senedine ait gelecek kapanış değerlerinin tahmin edilmesi	R Studio, Forecast
7. Test verilerinin oluşturulması	Verisetinden test verisetinin ayrılması	R Studio
8. Hata Metriklerinin Hesaplanması	Tahmin ve test verisetinin karşılaştırılması, model doğruluğunun ölçülmesi	R Studio, Forecast

3.2. LSTM-GRU-SimpleRNN

Çözüm Aşamaları	Yapılan İş	Çözüm Aracı, Yöntem, Teknik, Pogram vs.
1. Verilerin Elde Edilmesi	Hisse senedi verilerinin toplanması	Python,Pandas, Yahoo Finance
2. Veri Ön İşleme	Verilerin temizlenmesi, eksik verilerin kontrolü ve normalizasyonu	Python Pandas, Scikit-Learn
3. Özellik Seçimi	Tahmin için önemli özelliklerin seçimi	Python, Pandas, Scikit-Learn
4. Verinin Yeniden Şekillendirilmesi	Verinin denetimli öğrenme için uygun formata getirilmesi	Python, Pandas
5. Eğitim ve Test Verilerinin Hazırlanması	Verilerin eğitim ve test setlerine bölünmesi	Python, Scikit-Learn
6.LSTM,GRU,SimpleRNN Modellerinin oluşturulması ve eğitilmesi	LSTM,GRU, Simple RNN Algoritmaları ait modellerin oluşturulması ve eğitilmesi	Python, TensorFlow/Keras
7. Tahminlerin Yapılması ve değerlendirilmesi	Model ile test verisi üzerinde tahminlerin yapılması, gerçek değerlerle karşılaştırılması ve görselleştirilmesi	Python, TensorFlow/Keras Scikit-Learn,
8. Hata metriklerinin hesaplanması	Tahmin ve test verisetinin karşılaştırılması, model doğruluğunun ölçülmesi	Python, Scikit-Learn, Matplotlib

BÖLÜM 4. UYGULAMA

4.1. ARIMA modeli uygulaması

4.1.1. Verilerin Elde Edilmesi

Hisse senedi verilerinin Yahoo Finance sitesinden istenilen zaman dilimine göre temin edilmesi.

Veri setinin okunabilmesi için gerekli kütüphaneler yüklenir.

```
> library(forecast)
```

```
> library(ggplot2)
```

```
> library(tseries)
```

```
> library(readr)
```

```
> apple_gunluk = read_csv("elma.csv")
```

4.1.2. Zaman serisi oluşturma

Zaman serisi verisi oluşturulur.

```
> Apple = ts(apple_gunluk,frequency=365)
```

4.1.3. Durağanlık kontrolü

Durağanlık kpss test fonksiyonu ile edilir.


```
> kpss.test(Apple)
```

KPSS Test for Level Stationarity

data: Apple

KPSS Level = 35.375, Truncation lag parameter = 11, p-value = 0.01

```
> autoplot(Apple)
```



Şekil 9.APPLE hisse senedi

KPSS testinin sonucuna göre p-değeri 0.01 çıkmıştır , zaman serisi durağan değildir. Bu bilgiyi göz önünde bulundurarak, zaman serisini durağan hale getirmek için fark alma işlemi gerekmektedir.

4.1.4.Mevsimsellik kontrolü

‘tbats()’ fonksiyonunu kullanarak mevsimsel zaman serisi verilerini modellemek için kullanılıyor. Model çıktısında mevsimsel bileşenin var olup olmadığını kontrol ediyor

```
> Test_Mevsimsellik <- tbats(Apple)
> Mevsimsellik <- !is.null(Test_Mevsimsellik$seasonal)
> Mevsimsellik
[1] FALSE
```

Mevsimsellik değişkeni çağırıldığında içerisine atanan değer FALSE olduğundan zaman serisi mevsimsel değildir.

4.1.5.Model oluşturma

Autoarima fonksiyonu ile en uygun ARIMA parameterlerine sahip model elde edilir.

```
> Model<-auto.arima(Apple,seasonal=FALSE,
stepwise=FALSE,approximation=FALSE,trace=TRUE)
```

Model: | ARIMA(5,2,0)

Series: Apple

ARIMA(5,2,0)


Coefficients:

	ar1	ar2	ar3	ar4	ar5
	-0.8570	-0.7008	-0.5346	-0.3578	-0.1572
s.e.	0.0127	0.0162	0.0172	0.0162	0.0127

sigma^2 = 1.617: log likelihood = -10010.84


AIC=20033.68 AICc=20033.69 BIC=20073.91

Çıkan sonuca göre en uygun model ARIMA(5,2,0) olacak şekilde saptanmıştır.




Şekil 10.Durağanlık grafiği

Modelin otokorelasyon grafiği ve kısmi otokorelasyon grafiği verilmiştir.



Şekil 11.Otokorelasyon grafiği



Şekil 12.Kısmi otokorelasyon grafiği

4.1.6. Tahmin yapma

30 gün sonrasını tahmin edecek model oluşturulur.

```
> Tahmin_30gun <- forecast(Model,h=30)
```

```
> autoplot(Tahmin_30gun)
```

(2024.04.09-2024.05.21)Tarihleri arasındaki hisse senedi kapanış değerleri tahmin edilmiştir.

4.1.7.Eğitim ve test verilerinin hazırlanması

Tahminler sonucu oluşan grafiklerin tahmin ve gerçek değerlerinin oluşturulması ve görsel olarak yorumlanması.

```
> Tahminverisi = data.frame(Tahmin_30gun)
```

> Tahminverisi = Tahminverisi \$Point.Forecast

>Testverisi = Testverisi = tail(apple_gunluk,30)

4.1.8.Hata Metriklerinin Oluşturulması

Tahminlerin doğruluğunu ölçmek için “accuracy” fonksiyonu kullanılır. ME, MSE, MAE MAPE, RMSE, hata metrikleri hesaplanır.

>accuracy(Tahminverisi,Testverisi)

		ME	RMSE	MAE	MPE	MAPE
Test	set	-11.12454	12.70001	11.12454	-6.090234	6.090234

Tahmin ve Test verileri arasındaki korelasyon “correlation” fonksiyonu ile hesaplanır.

> correlation = cor(Tahminverisi,Testverisi, method = "pearson")

>print(correlation)

r=0.9022219

Tablo 1.ARIMA hata skorları

Hisse Senedi	MAE	RMSE	MAPE	r
ARIMA(5,2,0)	11.12454	12.70001	6.090234	0.90222

4.2. LSTM-GRU-SimpleRNN Modellerinin Uygulanması

4.2.1.Verilerin Elde Edilmesi

Hisse senedi verilerinin Yahoo Finance sitesinden istenilen zaman dilimine göre temin edilmesi. Sonrasında veri işleme ve veri analizi için gerekli olan pandas kütüphanesi eklenerek verilerin okunup işlenmesi sağlanır.


4.2.2.Verİ Ön İşleme

İlk adım olarak, veri setindeki eksik veya hatalı verileri kontrol edilir. Eksik veriler silinir. Tarih sütunu datetime formatına getirilir.Tarih sütunu indeks olarak ayarlanır. Verilerin (0,1)

arasında ölçeklendirilmesi için sklearn kütüphanesi eklenir. sklearn.preprocessing MinMaxScaler komutu ile veriler (0,1) arasında normalize edilir.

4.2.3.Özellik Seçimi

Verilerin hangi özellikleri içerdiğini anlamak için veri seti incelenir. Veri setinde tarih, açılış fiyatı, en yüksek fiyat, en düşük fiyat, kapanış fiyatı ve işlem hacmi gibi sütunlar bulunmakta. Bu değerler arası korelasyona bakılarak tahminde kullanılacak değişkenler belirlenir.



Şekil 13.Korelasyon matrisi

Modelde Volume(Hacim) değişkeninin veristeki diğer değişkenler arasında zayıf korelasyon gözlenmesinden kaynaklı olarak Volume parametresi modellere dahiledilmemiştir.

4.2.4. Verilerin yeniden şekillendirilmesi

Zaman serisi verileri denetimli öğrenme için yeniden şekillendirilir. series_to_supervised fonksiyonu ile , zaman serisi verilerini n_in=5 (girdi sekanları) ve n_out=1 (çıkış sekanları) bakarak denetimli öğrenme için hazır hale getirir. Fonksiyon, verileri kaydırarak geçmiş ve gelecekteki değerleri sütunlar halinde düzenler, böylece makine öğrenmesi modelleri için uygun bir format oluşturur.

4.2.5. Eğitim ve test setlerinin hazırlanması

Girdi ve çıktı değişkenleri belirlenir (X ve y). Veri seti, verilerin %80'ini eğitim, %20'sini test seti olarak ayrılacaktır. Eğitim seti, modelin öğrenmesi için kullanılır. Test seti, modelin performansını değerlendirmek için kullanılır. İşlemlerin uygulanabilmesi için sklearn kütüphanesinden train_test_split fonksiyonu çağırılır.

4.2.6. LSTM, GRU, Simple RNN Modellerinin oluşturulması ve eğitilmesi

LSTM GRU, SimpleRNN algoritmalarına ait parametreler her bir algoritma için aynı değerlerde belirlenmiş olup ve relu aktivasyon fonksiyonu modellerde kullanılmıştır. Modellerim katmanlarının sıralı bir şekilde ilerlemesi gerektiği için Keras kütüphanesinden Sequential modelini ve Dropout, Dense katmanlarını kullanırız. Bu yapı, kullanılan modelin her katmanını adım adım eklememizi sağlar. Tahmin algoritmalarındaki en büyük problemlerden biri aşırı öğrenme (overfitting) durumudur. Bu sorunu aşmak için algoritma katmanına Dropout katmanı eklenmiştir. Dense katmanı, çıktı katmanı olarak kullanılır. Algoritmaların yalnızca bir çıktısı olduğu için bu katmandaki nöron sayısı 1 olarak belirlenmiştir.

```
# PARAMETERS
layer_size = 2
units = 50
SEED = 123
learning_rate = 0.01
layer = 'SimpleRNN'
activation_function = 'relu'
dropout_rate = 0.01
epoch = 50
batch_size = 128
loss_function = 'mae'
optimizer = tf.keras.optimizers.Adam(learning_rate=learning_rate)
return_sequence = True
target = 'Close'
n_day = 5
train_size = 0.8
```

Şekil 15. Model parametreleri


```
model = Sequential()
model.add(
    SimpleRNN(units,
              activation=activation_function,
              input_shape=(X_train.shape[1], X_train.shape[2]),
              return_sequences=True))
model.add(Dropout(dropout_rate))
model.add(SimpleRNN(units, activation=activation_function))
model.add(Dropout(dropout_rate))
model.add(Dense(1))
model.compile(loss=loss_function, optimizer=optimizer)
history = model.fit(X_train,
                    y_train_df.to_numpy(),
                    epochs=epoch,
                    batch_size=batch_size,
                    validation_data=(X_test, y_test_df.to_numpy()),
                    verbose=1,
                    )
```

Şekil 14. Model mimarisi


4.2.7. Tahminlerin yapılması ve değerlendirilmesi

Eğitim verisi kullanılarak forecast fonksiyonu ile birlikte her bir algoritma için tahmin değerleri hesaplanır. Test setiyle tahminin çıktılarına ait grafik oluşturulur


GRU



Şekil 17. GRU kayıp fonksiyonu




Şekil 16. GRU tahmin değerlerinin dağılımları




Şekil 18. GRU gerçekleşen ve tahmin kapanış değerleri


LSTM



Şekil 19. LSTM kayıp fonksiyonu




Şekil 20. LSTM tahmin değerleri




Şekil 21.LSTM gerçekleştiren ve tahmin kapanış değerleri


SimpleRNN



Şekil 22.SimpleRNN kayıp fonksiyonu



Şekil 23.LSTM tahmin değerleri



Şekil 24.SimpleRNN gerçekleşen ve tahmin kapanış değerleri

4.2.8.Hata Metriklerinin Hesaplanması

Tahmin değerleri ve gerçek değerler arasındaki ilişkiden yola çıkarak “sklearn.metrics” kütüphanesi ile birlikte hata metrikleri hesaplanır.

Tablo 2.LSTM-GRU-SimpleRNN hata skorları


Model	MAE	RMSE	MAPE	r
GRU (Relu)	0.7836188	1.7006878	4.9781746	0.9996612
LSTM (Relu)	0.8299765	1.6659877	19.9529207	0.9996812
SimpleRNN (Relu)	1.3606414	2.54818212	22.781168	0.9997157

BÖLÜM 5. ANALİZ

Bu çalışmada, 12.06.2000 - 10.06.2024 tarihleri arasında Apple hisse senedi tahmini amacıyla kullanılan dört farklı modelin performansını karşılaştırmak için hata metrikleri analiz edilmiştir. İncelenen modeller arasında GRU (Relu), LSTM (Relu), SimpleRNN (Relu) ve ARIMA(5,2,0) bulunmaktadır. Performans değerlendirmesi için Ortalama Mutlak Hata (MAE), Kök Ortalama Kare Hata (RMSE), Ortalama Mutlak Yüzde Hata (MAPE) ve Korelasyon Katsayısı (r) gibi hata metrikleri kullanılmıştır.

Tablo 3. Tüm modellerin hata skorları

Model	MAE	RMSE	MAPE	r
GRU (Relu)	0.7836188	1.7006878	4.9781746	0.9996612
LSTM (Relu)	0.8299765	1.6659877	19.9529207	0.9996812
SimpleRNN (Relu)	1.3606414	2.54818212	22.781168	0.9997157
ARIMA (5,2,0)	11.12454	12.70001	6.090234	0.90222



Şekil 25. Hata skorlarına göre modeller grafiği


Ortalama Mutlak Hata (MAE): MAE, tahmin edilen değerler ile gerçek değerler arasındaki mutlak hata değerlerinin ortalamasını ifade eder. En düşük MAE değeri 0.7836188 ile GRU (Relu) modelinde gözlemlenmiştir, bu da GRU modelinin genel olarak en düşük hata oranına sahip olduğunu göstermektedir.

Kök Ortalama Kare Hata (RMSE): RMSE, hataların karelerinin ortalamasının karekökünü alarak büyük hatalara daha fazla ağırlık verir. LSTM (Relu) modeli, 1.6659877 ile en düşük

RMSE değerine sahip olup, büyük hataları minimize etme konusunda en iyi performansı göstermektedir.

Ortalama Mutlak Yüzde Hata (MAPE): MAPE, tahmin edilen değerler ile gerçek değerler arasındaki mutlak hata yüzdelерinin ortalamasıdır. GRU (Relu) modeli, %4.9781746 ile en düşük MAPE değerine sahiptir ve bu model yüzdesel olarak en doğru tahminleri gerçekleştirmiştir.

Korelasyon Katsayısı (r): Korelasyon katsayısı, tahmin edilen değerler ile gerçek değerler arasındaki doğrusal ilişkiyi ölçer. SimpleRNN (Relu) modeli, 0.9997157 ile en yüksek korelasyon katsayısına sahiptir, ancak diğer hata metrikleri açısından daha düşük performans sergilemiştir.



Şekil 26. Korelasyon değerlerine göre modeller

BÖLÜM 6. GERÇEKÇİ KISITLAR VE KOŞULLAR ALTINDA DEĞERLENDİRME


Bu çalışmada, makine öğrenmesi ve derin öğrenme yöntemleri kullanılarak yapılan piyasa tahminleri, ekonomik açıdan birçok önemli fayda sağlamaktadır. Öncelikle, ARIMA, LSTM, GRU ve Simple RNN gibi modellerin kullanılması, piyasa öngörülerinin doğruluğunu artırarak yatırımcıların daha bilinçli ve isabetli kararlar almalarına yardımcı olabilir. Daha doğru tahminler, sermayenin daha verimli kullanılmasını sağlayarak ekonomik etkinliği artırabilir. Yatırımcılar, bu tahminler sayesinde riskleri daha iyi yönetebilir ve beklenen bir düşüş öncesinde satış yaparak ya da artış öncesinde alım yaparak finansal kayıplarını minimize edebilirler.

Ancak, çalışmanızda sadece hisse senedine bağlı parametrelerin kullanılması, tahminlerin doğruluğunu sınırlandırabilir ve bu durum ekonomik analizlerin kapsamını daraltabilir. Finansal piyasalarda hisse senedi fiyatlarını etkileyen birçok dış etken bulunmaktadır; makroekonomik veriler, sektör trendleri, politik gelişmeler ve küresel ekonomik koşullar gibi faktörler, hisse senedi fiyatlarında önemli dalgalanmalara neden olabilir. Bu dış etkenlerin dikkate alınmaması, piyasa tahminlerinin gerçek dünya koşullarına uyumunu zorlaştırabilir.

Makine öğrenmesi modellerinin piyasa tahminlerindeki doğruluğu arttıkça, finansal piyasalarda beklenmeyen dalgalanmalar azalabilir ve piyasaların daha öngörülebilir ve istikrarlı olması sağlanabilir. Ancak, dış etkenlerin modelin dışında bırakılması, bu tahminlerin güvenilirliğini azaltabilir ve yatırımcıların karar verme süreçlerinde yanıltıcı sonuçlara yol açabilir.

BÖLÜM 7. SONUÇ

Bu çalışma, 12.06.2000 - 10.06.2024 tarihleri arasında Apple hisse senedi tahmininde kullanılan dört farklı modelin (GRU, LSTM, SimpleRNN, ARIMA) performansını değerlendirmiştir.



Şekil 27. Model karşılaştırması grafiği

Sonuçlar, GRU (Relu) modelinin düşük MAE ve MAPE değerleri ile en iyi performansı sergilediğini ortaya koymuştur. LSTM (Relu) modeli, düşük RMSE değeri ile büyük hataları minimize etme konusunda başarılı bulunmuş, ancak yüksek MAPE değeri bazı tahminlerde büyük yüzdesel hataların olduğunu göstermiştir. SimpleRNN (Relu) modeli, yüksek korelasyon katsayısına rağmen diğer hata metriklerinde daha düşük performans göstermiştir. Zaman serilerinde korelasyon katsayısını kullanmak, verinin otokorelasyon, trend, mevsimsellik ve durağanlık gibi özellikleri göz önünde bulundurularak dikkatle ele alınmalıdır. Korelasyon katsayısı, bazı durumlarda yanıltıcı sonuçlar verebilir ve zaman serisi verilerinin özelliklerine uygun alternatif analiz yöntemleri tercih edilmelidir. Bu nedenle,

zaman serisi analizinde korelasyon katsayısının yanında otokorelasyon fonksiyonu ve diğer uygun metrikler kullanmak daha doğru sonuçlar sağlar.

ARIMA (5,2,0) modeli ise diğer modellere kıyasla en düşük performansı sergilemiştir. Yüksek hata metrikleri ve düşük korelasyon katsayısı, ARIMA modelinin tahminlerde büyük hatalar yaptığını göstermektedir. ARIMA, geleneksel bir zaman serisi analiz yöntemi olarak, veri içindeki trendleri ve mevsimsellikleri belirlemede temel düzeyde başarılı olabilir, ancak derin öğrenme algoritmaları ile karşılaştırıldığında daha gelişmemiş bir yapıya sahiptir. Bu nedenle, ARIMA modeli, karmaşık ve yüksek boyutlu veri setlerinde derin öğrenme modellerine kıyasla daha fazla hata yapma eğilimindedir.

Genel olarak, bu modellerin performansı hisse senedi tahmininde makul derecede iyi sonuçlar vermektedir. Ancak, hisse senedi piyasalarının doğası gereği yüksek volatilité ve öngörülemezlik, tahminlerin doğruluğunu sınırlayan önemli faktörlerdir. Modellerin yüksek doğrulukta sonuçlar vermesi, hisse senedi tahmininin karmaşıklığını ve zorluğunu azaltmamaktadır. Hisse senedi fiyatlarının tahmini, finansal piyasalarda birçok değişkenin ve belirsizliğin etkisi altında kalmaktadır.

Makine öğrenmesi ve derin öğrenme algoritmaları, finansal zaman serilerinde güçlü araçlar olarak öne çıkmaktadır. Bu algoritmalar, büyük veri setlerindeki karmaşık desenleri öğrenme ve gelecekteki eğilimleri tahmin etme yetenekleri ile dikkat çekmektedir. GRU ve LSTM gibi tekrarlayan sinir ağları, özellikle uzun dönem bağımlılıkları modelleyerek zaman serisi verilerinde üstün performans sergileyebilir. Bununla birlikte, bu modellerin başarısı, kullanılan veri setinin kalitesine ve modelin uygun şekilde yapılandırılmasına bağlıdır. Hisse senedi tahmin modellerinin geliştirilmesi ve iyileştirilmesi için sürekli olarak yeni yöntemler ve daha kapsamlı veri setleri üzerinde çalışılması gerekmektedir. Bu bağlamda, makine öğrenmesi ve derin öğrenme algoritmaları, finansal tahminlerde daha hassas ve güvenilir sonuçlar elde etmek için gelecekte de önemli bir rol oynamaya devam edecektir.

KAYNAKLAR

- Bahadır, M. (2008). NYSE bünyesindeki ETF'lerin yapay sinir ağları ve Bayes Karar Modeli ile tahmini. Uluslararası Ekonomi ve Finans Dergisi, 5(2), 67-78.
- Kılıç, Ö. (2018). Destek Vektör Makineleri ile hisse senedi fiyat tahmini. Ekonomi ve Finans Araştırmaları Dergisi, 7(3), 120-135.
- Demirci, A., & Eren, M. (2019). LSTM ile hisse senedi fiyat tahmini. Bilgisayar ve Finansal Modelleme Dergisi, 8(1), 33-46.
- Tanyer, M. (2019). Finansal oranlı yapay sinir ağı modeli ile hisse değeri değişimi tahmini. Konya Teknik Üniversitesi.
- Eskişehir Osmangazi Üniversitesi. (2019). Makine Öğrenmesi Teknikleri ile Hisse Senedi Fiyat Tahmini. Eskişehir Osmangazi Üniversitesi
- Şişmanoğlu, A., Yılmaz, B., & Kaya, D. (2020). BLSTM-LSTM-GRU modelleri ile IBM hisse senedi tahmini. Finans ve Ekonomi Araştırmaları Dergisi, 12(3), 45-60.
- Kaya, B. (2021). Karar Ağaçları ve Rastgele Ormanlar ile hisse senedi fiyat tahmini. Finans ve Yatırım Analizleri Dergisi, 9(2), 45-59.
- Demirel, O., Yıldırım, S., & Aydın, M. (2021). MLP, SVM ve LSTM modelleri ile BİST 100 endeksindeki şirketlerin hisse senedi fiyat tahmini. Finansal Analiz ve Tahmin Dergisi, 10(4), 89-102.
- Altunbaş, C. (2021). Derin öğrenme ile hisse senedi piyasası tahmini. Adnan Menderes Üniversitesi, Ekonometri Anabilim Dalı.
- Karadağ, K. (2022). Hibrit derin öğrenme modelleri ile hisse senedi fiyat tahmini. Trakya Üniversitesi Sosyal Bilimler Enstitüsü.
- Toprak, E. (2023). LSTM+Evrişimli Sinir Ağı ve RFR modelleri ile Petkim hisse senedi fiyat tahmini. Veri Bilimi ve Makine Öğrenmesi Dergisi, 15(1), 22-35.